Michał Lidwa 3ID14A

Technologie IoT - Analityka Big Data (Projekt)

Temat projektu: Algierskie pożary lasów

O danych:

- Zbiór danych obejmuje 244 przypadki, które przegrupowują dane z dwóch regionów Algierii, mianowicie regionu Bejaia położonego w północno-wschodniej Algierii i regionu Sidi Bel-abbes położonego w północno-zachodniej Algierii.
- 122 instancje dla każdego regionu.
- Okres od czerwca 2012 r. do września 2012 r.
- Zestaw danych zawiera 11 atrybutów i 1 atrybut wyjściowy (klasa)
- 244 instancje zostały podzielone na klasy fire (138 klas), a not fire (106 klas).

Informacje o atrybutach:

- Date: (day/month/year) Dzień, miesiąc (od 'czerwiec' do 'wrzesień'), rok (2012)
- Temp: Temperatura w południe (maksymalna temperatura) w stopniach Celsjusza: 22 do 42
- RH: Wilgotność względna (w %): 21 do 90
- Ws: Prędkość wiatru (w km/h): 6 do 29
- Rain: Całkowity dzień w mm: 0 do 16,8 FWI Komponenty
- Indeks Dokładnego kodu wilgotności paliwa (FFMC) z systemu FWI: 28,6 do 92,5
- Indeks Kodu wilgotności Duffa (DMC) z systemu FWI: 1.1 do 65,9
- Indeks Kodu suszy (DC) z systemu FWI: od 7 do 220,4
- Indeks Początkowego spreadu (ISI) z systemu FWI: 0 do 18,5
- Indeks Budowania (BUI) z systemu FWI: 1.1 do 68
- Indeks Pogody pożarowej (FWI): 0 do 31.1
- Klasy: Fire and not Fire

Importowanie podstawowych bibliotek

In [ ]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import geopandas as gpd
from sklearn.model_selection import train_test_split
```

```
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import StandardScaler
from sklearn import metrics
from sklearn.metrics import mean_squared_error, mean_absolute_error, mean_absolu
from sklearn.tree import DecisionTreeClassifier
from sklearn import tree
from sklearn.tree import export_graphviz
from sklearn.metrics import classification_report
from sklearn.metrics import accuracy_score
from sklearn.metrics import ConfusionMatrixDisplay
from sklearn.ensemble import RandomForestRegressor
import sqlite3
import statsmodels.api as sm
from sklearn.datasets import load_iris
```

Odczyt danych z pliku sqlite3

In [ ]:
```
poloczenie = sqlite3.connect('Algerian_forest_fires_dataset.db')
```

Przerabianie danych na potrzeby analiz przez bilioteke pandas i zamkniecie bilbioteki

In [ ]:
```
dane = pd.read_sql_query("SELECT * FROM Algerian_forest_fires_dataset ", polocze
```

In [ ]:
```
poloczenie.close()
```

Wyswietlenie informacji o danych

In [ ]:
```
dane.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 247 entries, 0 to 246
Data columns (total 14 columns):
 #   Column       Non-Null Count  Dtype 
---  ------       --------------  ----- 
 0   day          246 non-null    object
 1   month        245 non-null    object
 2   year         245 non-null    object
 3   Temperature  245 non-null    object
 4   RH           245 non-null    object
 5   Ws           245 non-null    object
 6   Rain         245 non-null    object
 7   FFMC         245 non-null    object
 8   DMC          245 non-null    object
 9   DC           245 non-null    object
 10  ISI          245 non-null    object
 11  BUI          245 non-null    object
 12  FWI          245 non-null    object
 13  Classes      244 non-null    object
dtypes: object(14)
memory usage: 27.1+ KB
```

Wyświetlenie kolumn danych

In [ ]:
```
dane.columns
```

Out[ ]:
```
Index(['day', 'month', 'year', 'Temperature', 'RH', 'Ws', 'Rain', 'FFMC',
       'DMC', 'DC', 'ISI', 'BUI', 'FWI', 'Classes'],
      dtype='object')
```

Wyświetlenie ilosci danych

In [ ]:
```
dane.nunique()
```

Out[ ]:
```
day             33
month            5
year             2
Temperature     20
RH              63
Ws              19
Rain            40
FFMC           174
DMC            167
DC             199
ISI            107
BUI            175
FWI            127
Classes          9
dtype: int64
```

Wyswietlenie pierwszych 5 wierszy danych

In [ ]:
```
dane.head()
```

Out[ ]:

	day	month	year	Temperature	RH	Ws	Rain	FFMC	DMC	DC	ISI	BUI	FWI	Classes
0	1	6	2012	29	57	18	0.0	65.7	3.4	7.6	1.3	3.4	0.5	not fire
1	2	6	2012	29	61	13	1.3	64.4	4.1	7.6	1	3.9	0.4	not fire
2	3	6	2012	26	82	22	13.1	47.1	2.5	7.1	0.3	2.7	0.1	not fire
3	4	6	2012	25	89	13	2.5	28.6	1.3	6.9	0	1.7	0	not fire
4	5	6	2012	27	77	16	0.0	64.8	3	14.2	1.2	3.9	0.5	not fire

Wyświetlenie ostatnich 5 wierszy danych

In [ ]:
```
dane.tail()
```

Out[ ]:

	day	month	year	Temperature	RH	Ws	Rain	FFMC	DMC	DC	ISI	BUI	FWI	Class
242	26	9	2012	30	65	14	0.0	85.4	16	44.5	4.5	16.9	6.5	f
243	27	9	2012	28	87	15	4.4	41.1	6.5	8	0.1	6.2	0	not f
244	28	9	2012	27	87	29	0.5	45.9	3.5	7.9	0.4	3.4	0.2	not f
245	29	9	2012	24	54	18	0.1	79.7	4.3	15.2	1.7	5.1	0.7	not f
246	30	9	2012	24	64	15	0.2	67.3	3.8	16.5	1.2	4.8	0.5	not f

Opis ilosc danych w tabeli kategoriami

In [ ]:
```
dane.describe()
```

Out[ ]:

	day	month	year	Temperature	RH	Ws	Rain	FFMC	DMC	DC	ISI	BUI	FW
count	246	245	245	245	245	245	245.0	245.0	245.0	245	245.0	245	245.(
unique	33	5	2	20	63	19	40.0	174.0	167.0	199	107.0	175	127.(
top	1	7	2012	35	64	14	0.0	88.9	7.9	8	1.1	3	0.4
freq	8	62	244	29	10	43	133.0	8.0	5.0	5	8.0	5	12.(

Sprawdzanie wartości które sa puste (null)

In [ ]:
```
dane[dane.isnull().any(axis=1)]
```

Out[ ]:

	day	month	year	Temperature	RH	Ws	Rain	FFMC	DMC	DC	ISI	BU
122	None	None	None	None	None	None	None	None	None	None	None	Nor
123	Sidi-Bel Abbes Region Dataset	None	None	None	None	None	None	None	None	None	None	Nor
168	14	7	2012	37	37	18	0.2	88.9	12.9	14.69	12.5	10

Podsumowanie danych ile są puste dla danego atrybutu

In [ ]:
```
dane.isnull().sum()
```

Out[ ]:
```
day            1
month          2
year           2
Temperature    2
RH             2
Ws             2
Rain           2
FFMC           2
DMC            2
DC             2
ISI            2
BUI            2
FWI            2
Classes        3
dtype: int64
```

Usunięcie danych gdzie jest brak danych (null)

In [ ]:
```
dane=dane.dropna().reset_index(drop=True)
```

Sprawdzanie danych po usunięciu

In [ ]:
```
dane[dane.isnull().any(axis=1)]
```

Out[ ]:

day	month	year	Temperature	RH	Ws	Rain	FFMC	DMC	DC	ISI	BUI	FWI	Classes

In [ ]:
```
dane.isnull().sum()
```

Out[ ]:
```
day            0
month          0
year           0
Temperature    0
RH             0
Ws             0
Rain           0
FFMC           0
DMC            0
DC             0
ISI            0
BUI            0
FWI            0
Classes        0
dtype: int64
```

Podział danych ze względu na region 1 - Bejaia Region 2 - Sidi-Bel Abbes

In [ ]:
```
dane.loc[:122, 'Region'] = 1
dane.loc[122:, 'Region'] = 2
dane[['Region']] = dane[['Region']].astype('int64')
```

Wyświetlenie pierwszych 5 dancyh wirszy dla Regionu Bejaia

In [ ]:
```
dane.head()
```

Out[ ]:

	day	month	year	Temperature	RH	Ws	Rain	FFMC	DMC	DC	ISI	BUI	FWI	Classes
0	1	6	2012	29	57	18	0.0	65.7	3.4	7.6	1.3	3.4	0.5	not fire
1	2	6	2012	29	61	13	1.3	64.4	4.1	7.6	1	3.9	0.4	not fire
2	3	6	2012	26	82	22	13.1	47.1	2.5	7.1	0.3	2.7	0.1	not fire
3	4	6	2012	25	89	13	2.5	28.6	1.3	6.9	0	1.7	0	not fire
4	5	6	2012	27	77	16	0.0	64.8	3	14.2	1.2	3.9	0.5	not fire

Wyświetlenie pierwszych 5 dancyh wirszy dla Regionu Sidi-Bel Abbes

In [ ]:
```
dane.tail()
```

Out[ ]:

	day	month	year	Temperature	RH	Ws	Rain	FFMC	DMC	DC	ISI	BUI	FWI	Class
239	26	9	2012	30	65	14	0.0	85.4	16	44.5	4.5	16.9	6.5	f
240	27	9	2012	28	87	15	4.4	41.1	6.5	8	0.1	6.2	0	not f
241	28	9	2012	27	87	29	0.5	45.9	3.5	7.9	0.4	3.4	0.2	not f
242	29	9	2012	24	54	18	0.1	79.7	4.3	15.2	1.7	5.1	0.7	not f
243	30	9	2012	24	64	15	0.2	67.3	3.8	16.5	1.2	4.8	0.5	not f

Usuniecie lini 122 ze wzgledu na duplikacje nazw atrybutów

In [ ]:
```
dane = dane.drop(122).reset_index(drop=True)
```

Przerabianie danych na dataframe na potrzeby analizy

In [ ]:
```
dane.shape
```

Out[ ]:
```
(243, 15)
```

In [ ]:
```
dane[dane.isnull().any(axis=1)]
```

Out[ ]:

	day	month	year	Temperature	RH	Ws	Rain	FFMC	DMC	DC	ISI	BUI	FWI	Classes	F

Naprawa kolumn

In [ ]:
```
dane.columns
```

Out[ ]:
```
Index(['day', 'month', 'year', 'Temperature', 'RH', 'Ws', 'Rain', 'FFMC',
       'DMC', 'DC', 'ISI', 'BUI', 'FWI', 'Classes', 'Region'],
      dtype='object')
```

In [ ]:
```
dane.columns = dane.columns.str.strip()
```

In [ ]:
```
dane.columns
```

Out[ ]:
```
Index(['day', 'month', 'year', 'Temperature', 'RH', 'Ws', 'Rain', 'FFMC',
       'DMC', 'DC', 'ISI', 'BUI', 'FWI', 'Classes', 'Region'],
      dtype='object')
```

Zmiana typów danych na wymagane typy danych dla odpowiednich funkcji do analizy

In [ ]:
```
dane[['month','day','year','Temperature','RH','Ws']]=dane[['month','day','year',
```

In [ ]:
```
obkiekty=[noweobiekty for noweobiekty in dane.columns if dane[noweobiekty].dtype
```

In [ ]:
```
for i in obkiekty:
    if i!='Classes':
        dane[i]=dane[i].astype(float)
```

Wyświetlenie danych po operacjach

In [ ]:
```
dane.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 243 entries, 0 to 242
Data columns (total 15 columns):
 #   Column       Non-Null Count  Dtype  
---  ------       --------------  -----  
 0   day          243 non-null    int64  
 1   month        243 non-null    int64  
 2   year         243 non-null    int64  
 3   Temperature  243 non-null    int64  
 4   RH           243 non-null    int64  
 5   Ws           243 non-null    int64  
 6   Rain         243 non-null    float64
 7   FFMC         243 non-null    float64
 8   DMC          243 non-null    float64
 9   DC           243 non-null    float64
 10  ISI          243 non-null    float64
 11  BUI          243 non-null    float64
 12  FWI          243 non-null    float64
 13  Classes      243 non-null    object 
 14  Region       243 non-null    int64  
dtypes: float64(7), int64(7), object(1)
memory usage: 28.6+ KB
```

In [ ]:
```
dane.describe()
```

Out[ ]:

	day	month	year	Temperature	RH	Ws	Rain	
count	243.000000	243.000000	243.0	243.000000	243.000000	243.000000	243.000000	243.0(
mean	15.761317	7.502058	2012.0	32.152263	62.041152	15.493827	0.762963	77.8
std	8.842552	1.114793	0.0	3.628039	14.828160	2.811385	2.003207	14.3
min	1.000000	6.000000	2012.0	22.000000	21.000000	6.000000	0.000000	28.6(
25%	8.000000	7.000000	2012.0	30.000000	52.500000	14.000000	0.000000	71.8
50%	16.000000	8.000000	2012.0	32.000000	63.000000	15.000000	0.000000	83.3(
75%	23.000000	8.000000	2012.0	35.000000	73.500000	17.000000	0.500000	88.3(
max	31.000000	9.000000	2012.0	42.000000	90.000000	29.000000	16.800000	96.0(

Ustawnie klasyfikacji dla klas

In [ ]:
```
dane["Classes"].value_counts()
```

Out[ ]:
```
fire            131
not fire        101
fire              4
fire              2
not fire          2
not fire          1
not fire          1
not fire          1
Name: Classes, dtype: int64
```

In [ ]:
```
dane.Classes = dane.Classes.str.strip()
```

In [ ]:
```
dane["Classes"].value_counts()
```

Out[ ]:
```
fire        137
not fire    106
Name: Classes, dtype: int64
```

Ustawienie klasy:

- not fire na 0
- fire na 1

In [ ]:
```
dane['Classes']= np.where(dane['Classes']== 'not fire',0,1)
```

In [ ]:
```
dane.Classes.value_counts()
```

Out[ ]:
```
1    137
0    106
Name: Classes, dtype: int64
```

Wyświetlenie korelacji

In [ ]:
```
dane.corr(numeric_only=True)
```

Out[ ]:

	day	month	year	Temperature	RH	Ws	Rain	FFM
day	1.000000	-0.000369	NaN	0.097227	-0.076034	0.047812	-0.112523	0.22495
month	-0.000369	1.000000	NaN	-0.056781	-0.041252	-0.039880	0.034822	0.01703
year	NaN	NaN	NaN	NaN	NaN	NaN	NaN	Na
Temperature	0.097227	-0.056781	NaN	1.000000	-0.651400	-0.284510	-0.326492	0.67656
RH	-0.076034	-0.041252	NaN	-0.651400	1.000000	0.244048	0.222356	-0.64487
Ws	0.047812	-0.039880	NaN	-0.284510	0.244048	1.000000	0.171506	-0.16654
Rain	-0.112523	0.034822	NaN	-0.326492	0.222356	0.171506	1.000000	-0.54390
FFMC	0.224956	0.017030	NaN	0.676568	-0.644873	-0.166548	-0.543906	1.00000
DMC	0.491514	0.067943	NaN	0.485687	-0.408519	-0.000721	-0.288773	0.60360
DC	0.527952	0.126511	NaN	0.376284	-0.226941	0.079135	-0.298023	0.50739
ISI	0.180543	0.065608	NaN	0.603871	-0.686667	0.008532	-0.347484	0.74000
BUI	0.517117	0.085073	NaN	0.459789	-0.353841	0.031438	-0.299852	0.59201
FWI	0.350781	0.082639	NaN	0.566670	-0.580957	0.032368	-0.324422	0.69113
Classes	0.202840	0.024004	NaN	0.516015	-0.432161	-0.069964	-0.379097	0.76949
Region	0.000821	0.001857	NaN	0.269555	-0.402682	-0.181160	-0.040013	0.22224

In [ ]:
```
sns.set(style="white")
korelacja = dane.corr(numeric_only=True)
plt.figure(figsize=(15, 15))
sns.heatmap(korelacja, annot=True, cmap='coolwarm', square=True)
plt.title('Macierz korelacji dla danych ogolnych z datami', fontsize=16)
plt.show()
```

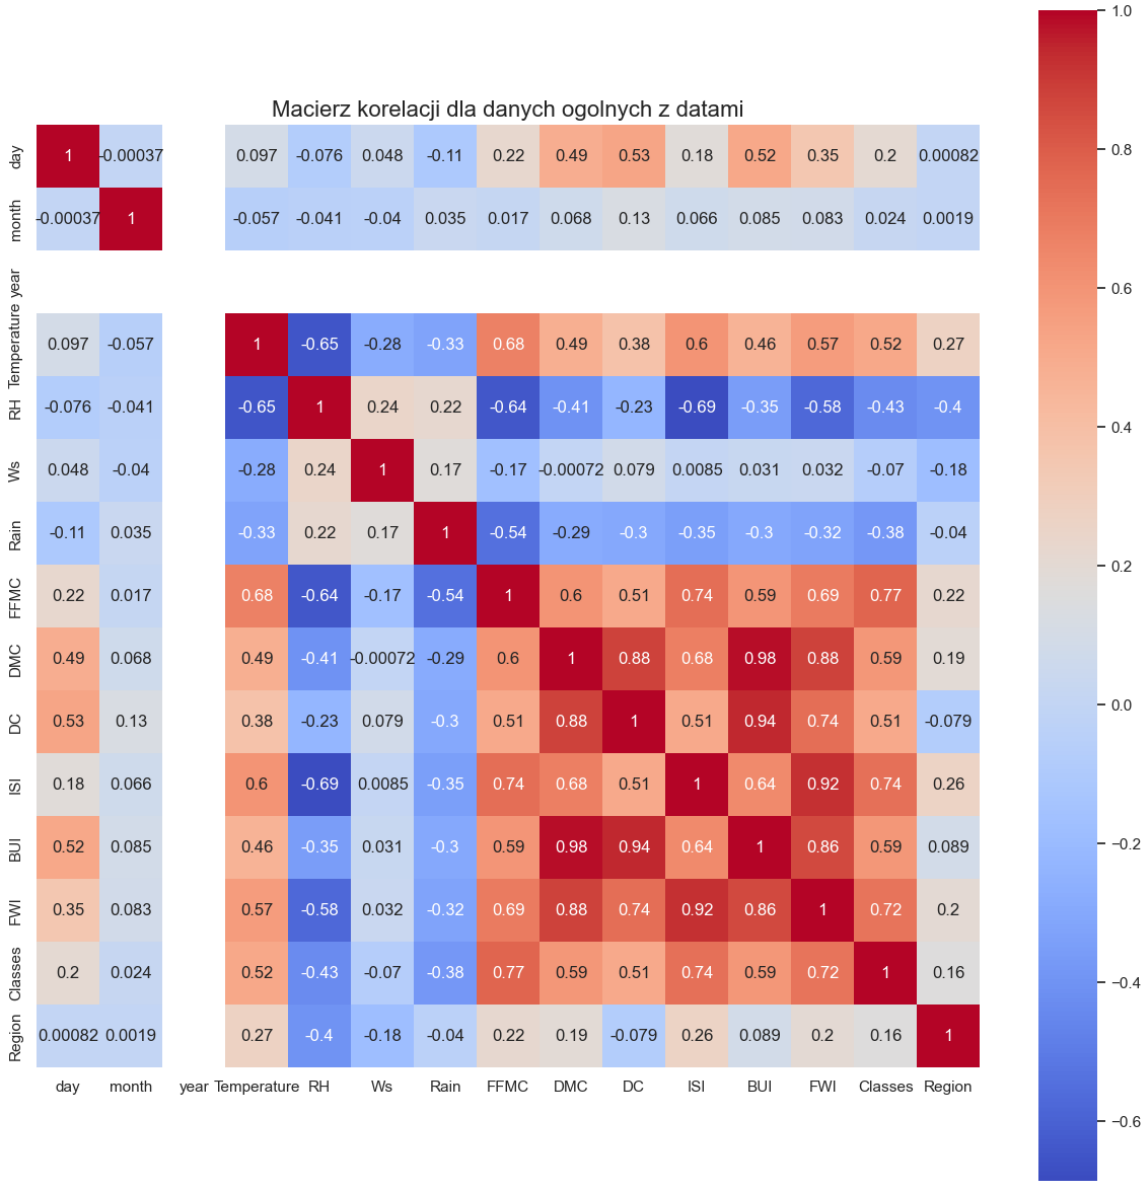

Wyświetlenie histogramu

In [ ]:
```
dane.hist(bins=100, figsize=(20, 15), ec='b')
plt.show()
```

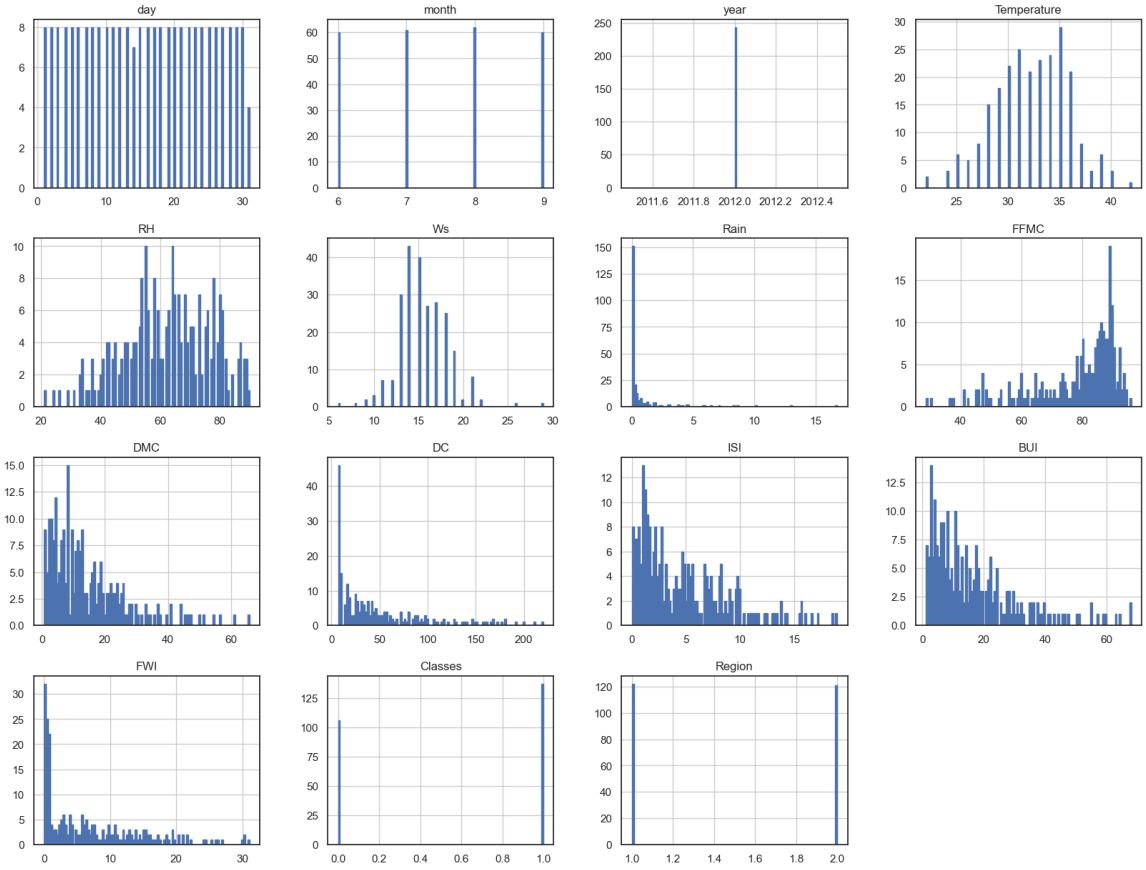

Wykresy rozrzutów

In [ ]:
```
sns.pairplot(dane, height=1.5,
             aspect=1,)
```

Out[ ]:
```
<seaborn.axisgrid.PairGrid at 0x1e963591a50>
```

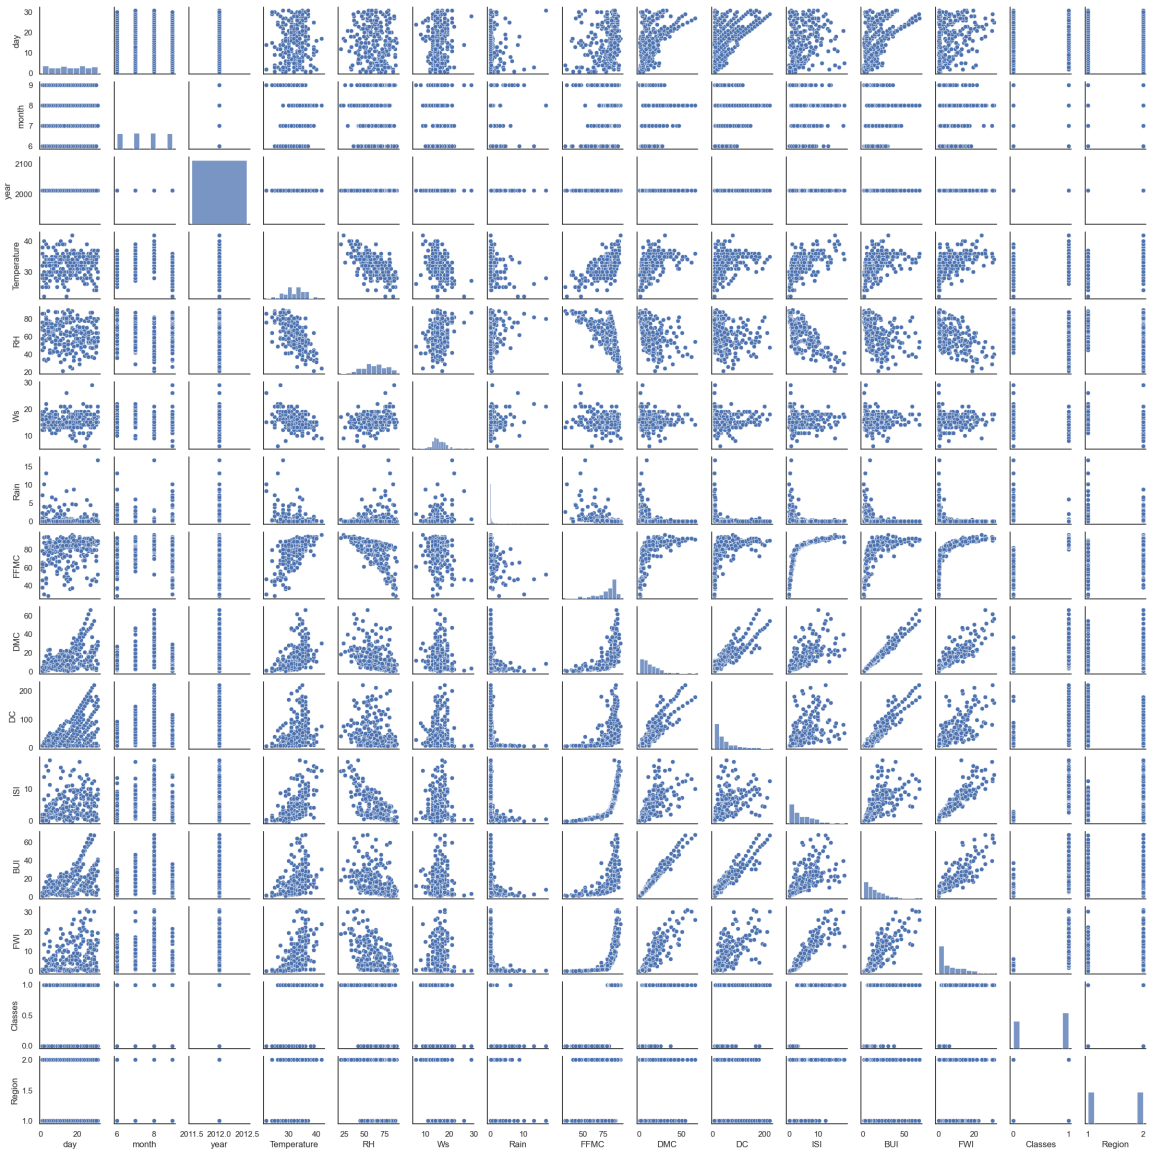

Procent porżarów według klasy

In [ ]:
```
procent = dane.Classes.value_counts(normalize=True)*100
procent
```

Out[ ]:
```
1    56.378601
0    43.621399
Name: Classes, dtype: float64
```

Analiza pożarów dla Algerii

- klasa 0 - Not Fire
- klasa 1 - Fire

In [ ]:
```
sns.countplot(x='Classes', data=dane, palette="tab10")
plt.title('Dane według klasy wykres słupkowy \n 0: Not Fire || 1: Fire', fontsiz
```

Out[ ]:
```
Text(0.5, 1.0, 'Dane według klasy wykres słupkowy \n 0: Not Fire || 1: Fire')
```

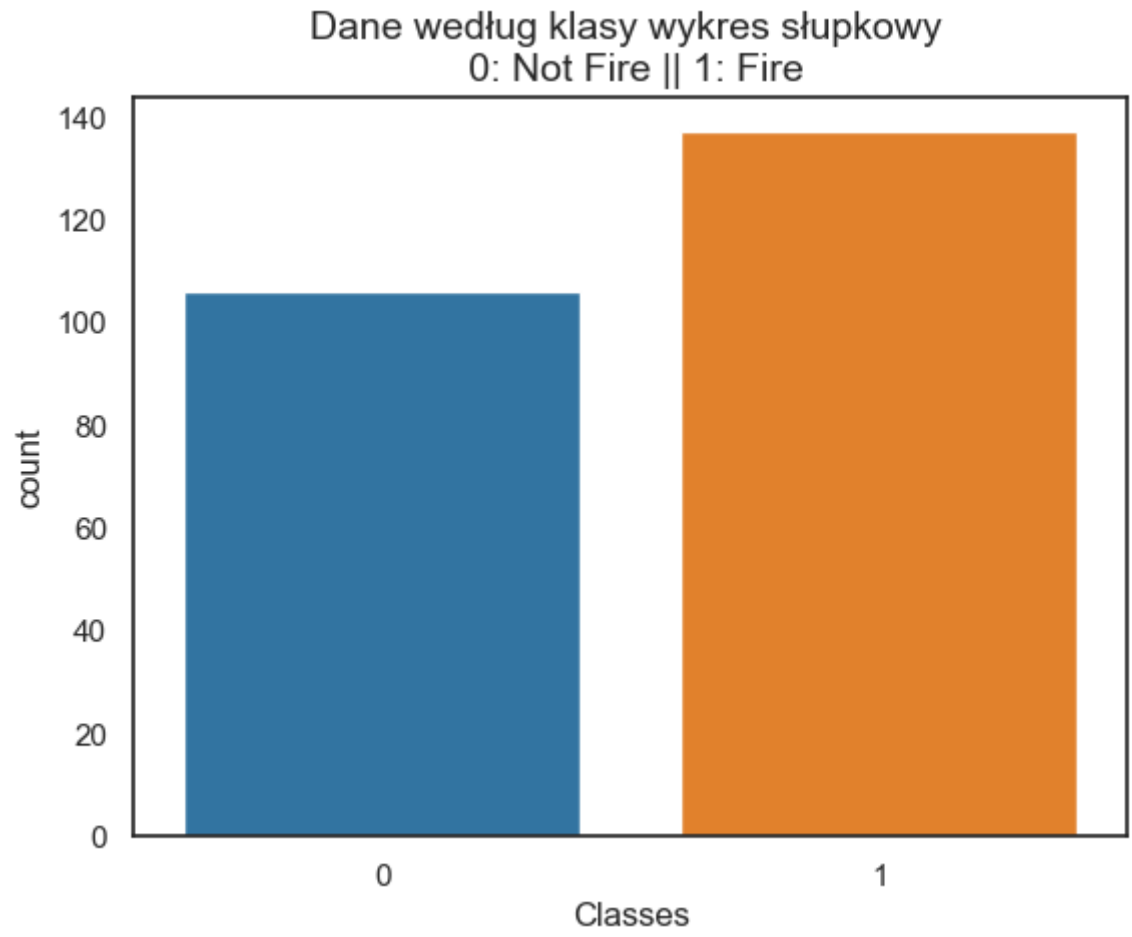

Wykres kołowy

In [ ]:
```
classeslabels = ["Fire", "Not-Fire"]
plt.figure(figsize=(12, 7))
plt.pie(procent, labels=classeslabels, autopct='%1.1f%%')
plt.title("Wykres kołowy", fontsize=15)
plt.show()
```

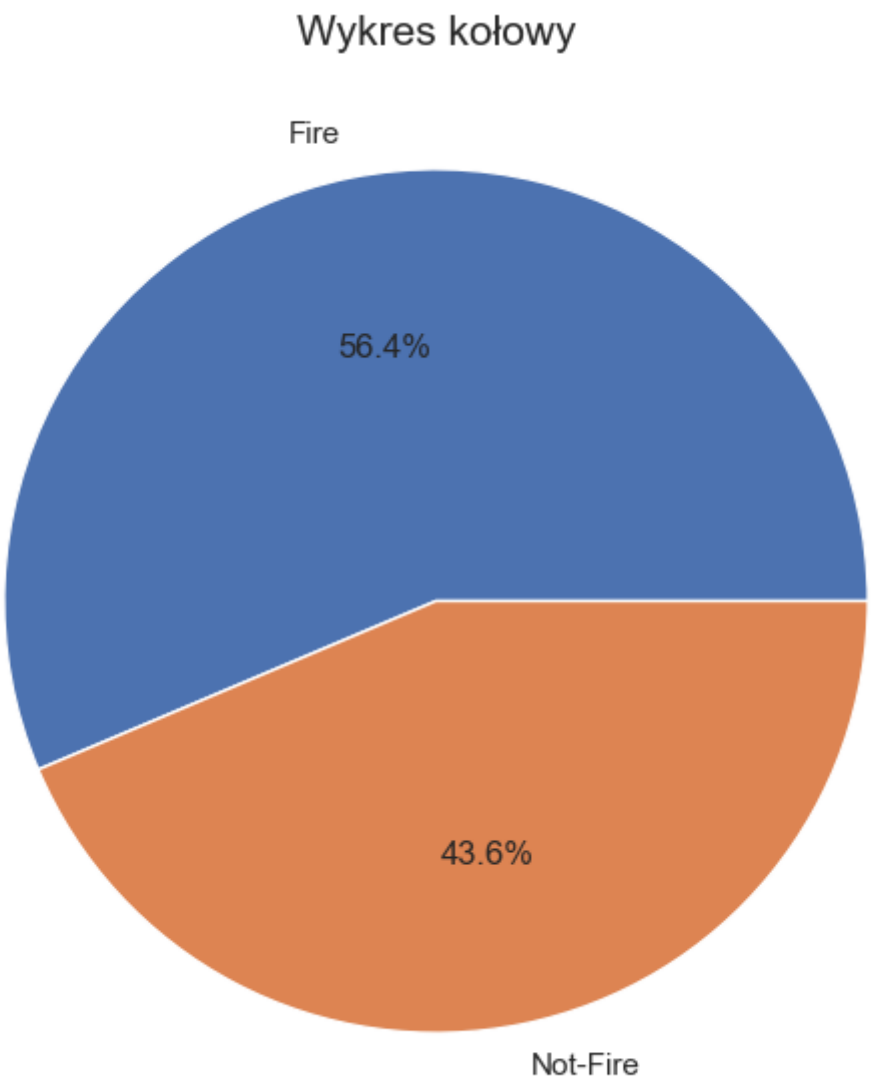

Zaznaczenie regionów gdzie są pożary:

- Kolor czerowny - Bejaia
- Kolor niebieski - Sidi Bel Abbes

In [ ]:
```
mapaalgerii = gpd.read_file(
    r'.\dza_admbnda_unhcr2020_shp\dza_admbnda_adm2_unhcr_20200120.shp')
bejaia = mapaalgerii.loc[mapaalgerii['ADM2_EN'] == 'Bejaia'].to_crs(epsg=32632)
sidi_bel_abbes = mapaalgerii.loc[mapaalgerii['ADM2_EN']
                                 == 'Sidi Bel Abbes'].to_crs(epsg=32632)

fig, ax = plt.subplots(figsize=(10, 10))
mapaalgerii.to_crs(epsg=32632).plot(
    ax=ax, color='lightgray', edgecolor='black')
bejaia.boundary.plot(ax=ax, color='red', linewidth=2)
sidi_bel_abbes.boundary.plot(ax=ax, color='blue', linewidth=2)

ax.annotate('', xy=(bejaia.centroid.x.iloc[0], bejaia.centroid.y.iloc[0]),
            color='red', fontsize=12, ha='center')
ax.annotate('', xy=(sidi_bel_abbes.centroid.x.iloc[0],
            sidi_bel_abbes.centroid.y.iloc[0]), color='blue', fontsize=12, ha='c

plt.show()
```

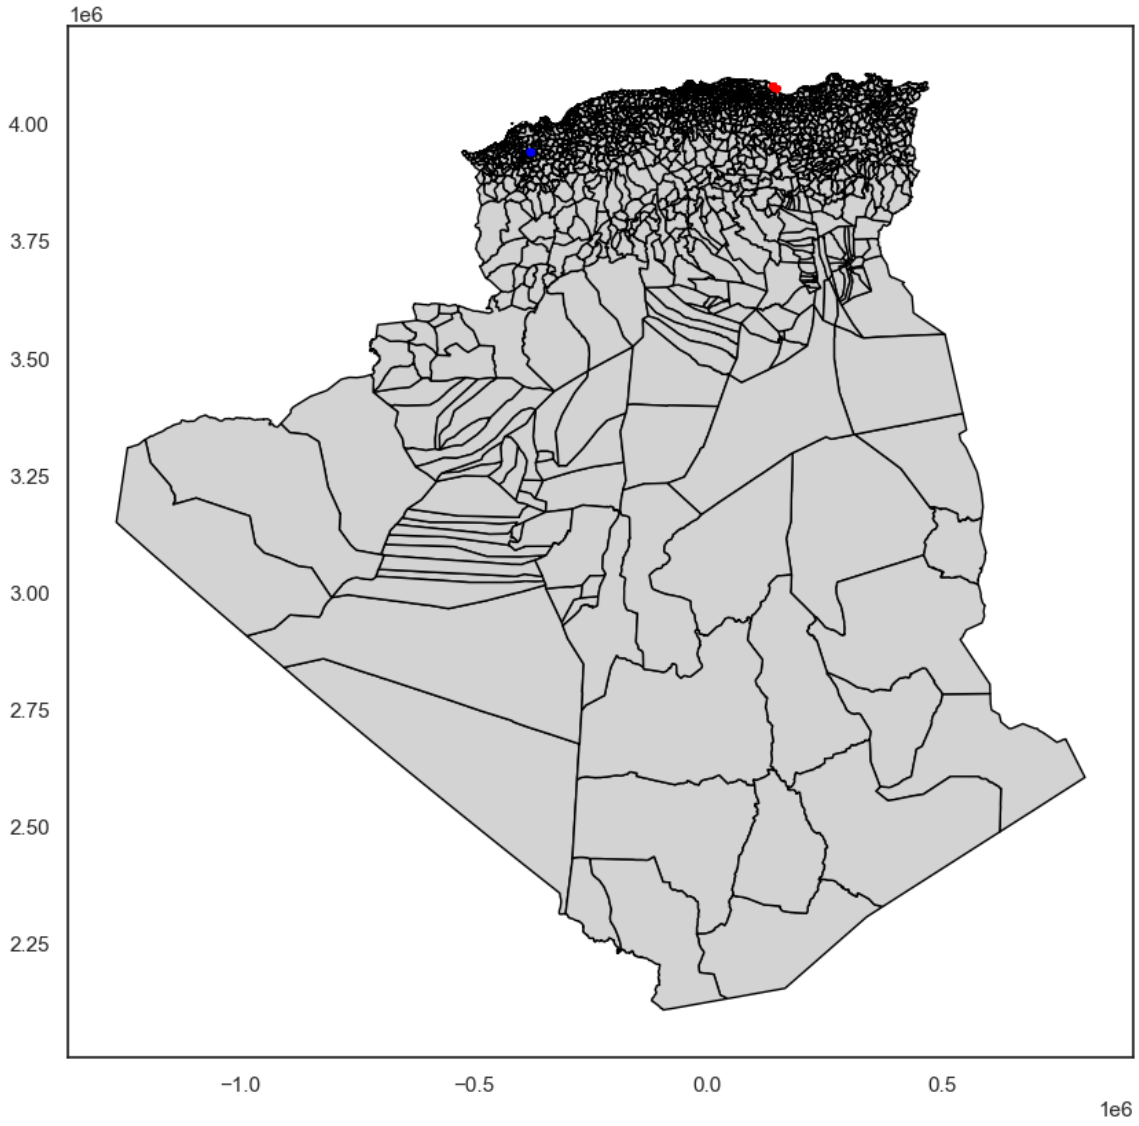

Analiza pożarów dla Algerii dla danego regionu

- klasa 0 - Not Fire
- klasa 1 - Fire

In [ ]:
```
etykietyklasy = ['Not Fire', 'Fire']

mapabejaia = '.\dza_admbnda_unhcr2020_shp\dza_admbnda_adm2_unhcr_20200120.shp'
danemapy = gpd.read_file(mapabejaia)

bejaia = danemapy[danemapy['ADM2_EN'] == 'Bejaia']


bejaia_pozar = dane[dane['Region'] == 1]

procentbejaia = bejaia_pozar['Classes'].value_counts(normalize=True) * 100

fig, ax = plt.subplots(figsize=(10, 10))
bejaia.plot(ax=ax, alpha=0.5)

for idx, row in bejaia.iterrows():
    for i, val in enumerate(procentbejaia):
        if i == 0:
            color = 'blue'
```

```
            text = f"{etykietyklasy[0]}: {val:.1f}%"
            x_offset = -0.030
        else:
            color = 'red'
            text = f"{etykietyklasy[1]}: {val:.1f}%"
            x_offset = 0.050
        ax.annotate(text=text, xy=(
            row.geometry.centroid.x + x_offset, row.geometry.centroid.y), color=


plt.title('Procent pożarów dla regionu  Bejaia w procentach na mapie')


plt.show()
```

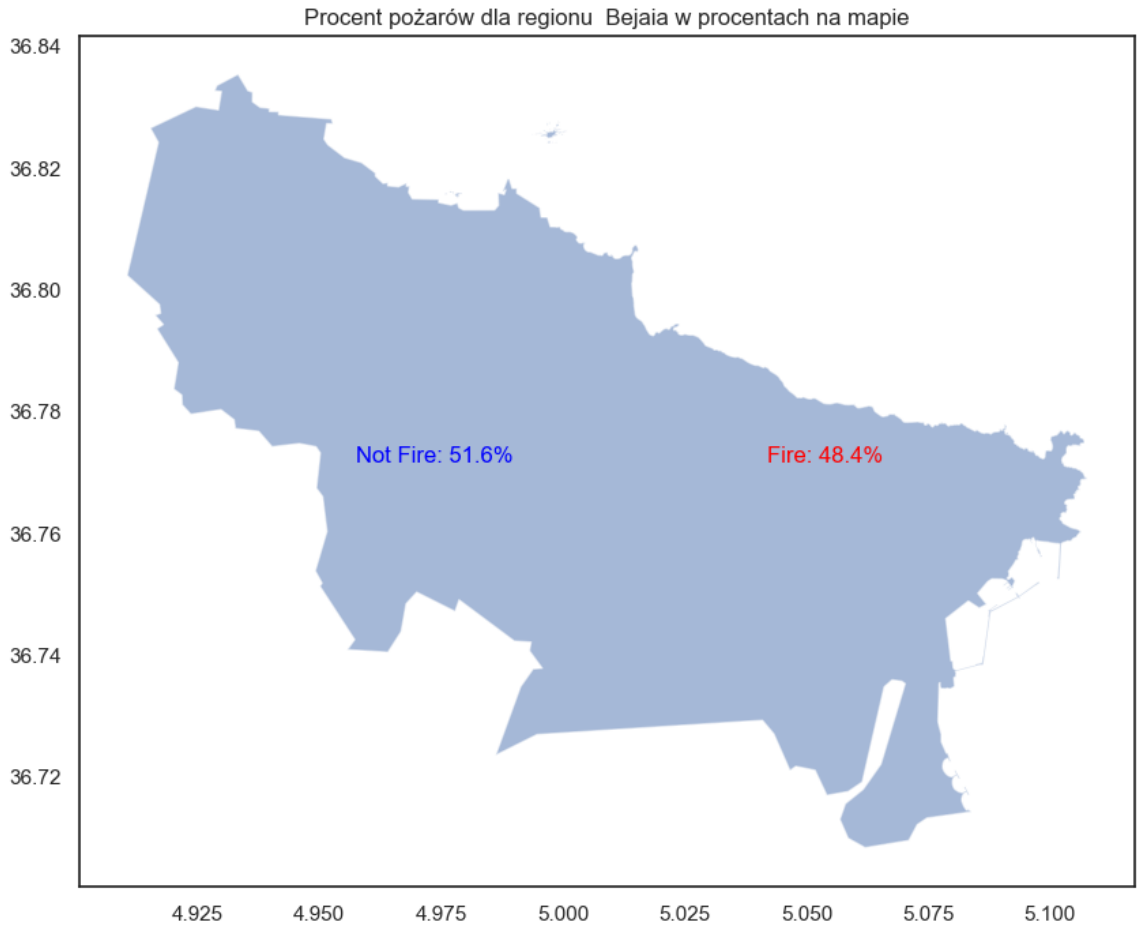

In [ ]:
```
etykietyklasy = ['Not Fire', 'Fire']

mapa_sidi_bel_abbes = '.\dza_admbnda_unhcr2020_shp\dza_admbnda_adm2_unhcr_202001
danemapy = gpd.read_file(mapa_sidi_bel_abbes)

Sidi_bel_abbes = danemapy[danemapy['ADM2_EN'] == 'Sidi Bel Abbes']


Sidi_bel_abbes_pozar= dane[dane['Region'] == 2]

procentsidibel = Sidi_bel_abbes_pozar['Classes'].value_counts(normalize=True) *

fig, ax = plt.subplots(figsize=(10, 10))
Sidi_bel_abbes.plot(ax=ax, alpha=0.5)

for idx, row in Sidi_bel_abbes.iterrows():
```

```
    for i, val in enumerate(procentsidibel):
        if i == 0:
            color = 'blue'
            text = f"{etykietyklasy[0]}: {val:.1f}%"
            x_offset = -0.030
        else:
            color = 'red'
            text = f"{etykietyklasy[1]}: {val:.1f}%"
            x_offset = 0.040
        ax.annotate(text=text, xy=(
            row.geometry.centroid.x + x_offset, row.geometry.centroid.y), color=


plt.title('Procent pożarów dla regionu  Sidi Bel Abbes w procentach na mapie')


plt.show()
```

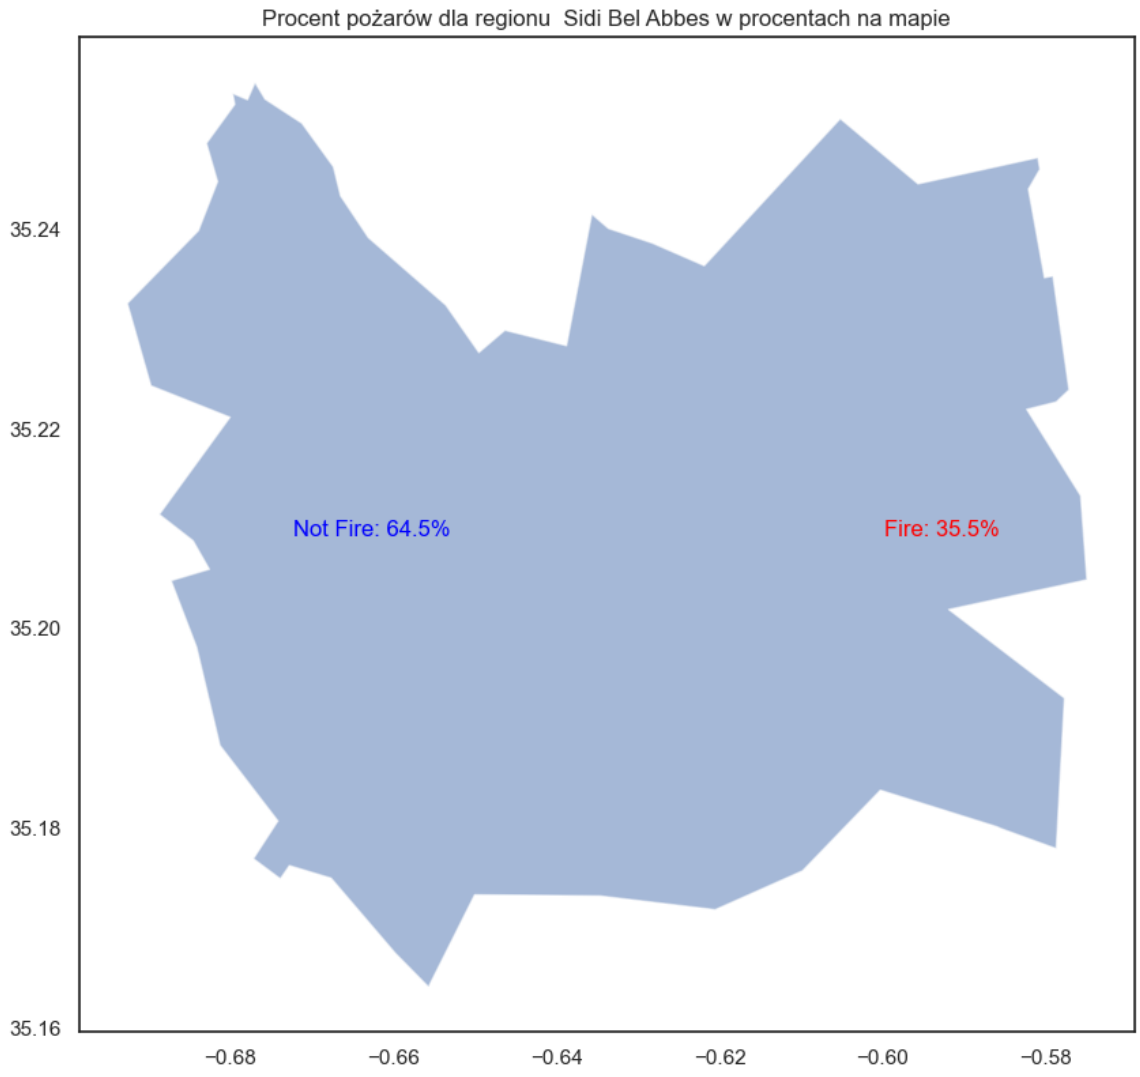

Analiza pożarów dla Algerii i dla danych regionów dla danego miesiąca

- klasa 0 - Not Fire
- klasa 1 - Fire

In [ ]:
```
plt.subplots(figsize=(13, 6))
sns.set_style('whitegrid')
sns.countplot(x='month', hue='Classes', data=dane,
```

```
                ec='black', palette='colorblind')
plt.title('Analiza pożarów dla Algerii w miesiacach',
          fontsize=18, weight='bold')
plt.ylabel('Liczba', weight='bold')
plt.xlabel('Miesiace', weight='bold')
plt.legend(loc='upper right')
plt.xticks(np.arange(4), ['Czerwiec', 'Lipiec', 'Sierpien', 'Wrzesien',])
plt.grid(alpha=0.5, axis='y')
plt.show()
```

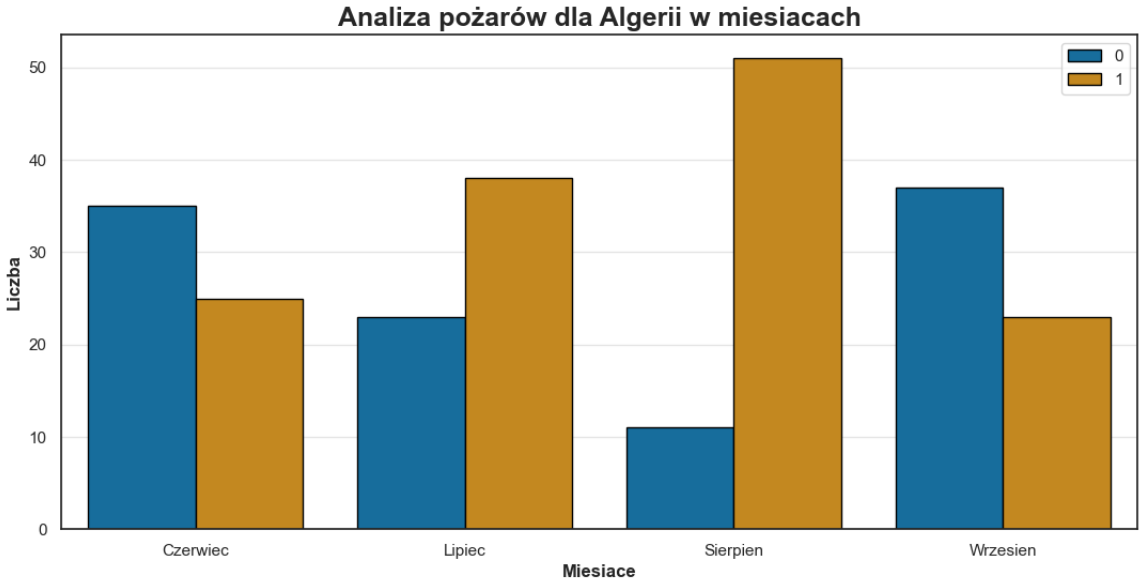

In [ ]:

```
nowedane = dane.loc[dane['Region'] == 1]
plt.subplots(figsize=(13, 6))
sns.set_style('whitegrid')
sns.countplot(x='month', hue='Classes', data=nowedane,
              ec='black', palette='colorblind')
plt.title('Analiza pożarów dla regionu Bejaia w miesiacach',
          fontsize=18, weight='bold')
plt.ylabel('Liczba', weight='bold')
plt.xlabel('Miesiace', weight='bold')
plt.legend(loc='upper right')
plt.xticks(np.arange(4), ['Czerwiec', 'Lipiec', 'Sierpien', 'Wrzesien',])
plt.grid(alpha=0.5, axis='y')
plt.show()
```

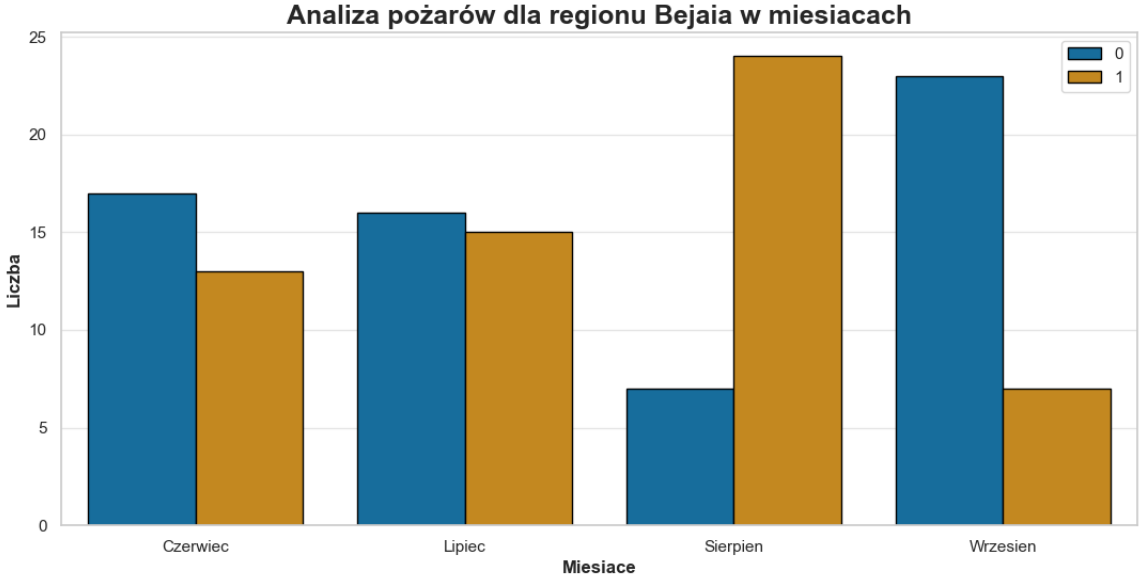

In [ ]:
```
nowedane = dane.loc[dane['Region'] == 2]
plt.subplots(figsize=(13, 6))
sns.set_style('whitegrid')
sns.countplot(x='month', hue='Classes', data=nowedane,
              ec='black', palette='colorblind')
plt.title('Analiza pożarów dla regionu Sidi-Bel Abbes w miesiacach',
          fontsize=18, weight='bold')
plt.ylabel('Liczba', weight='bold')
plt.xlabel('Miesiace', weight='bold')
plt.legend(loc='upper right')
plt.xticks(np.arange(4), ['Czerwiec', 'Lipiec', 'Sierpien', 'Wrzesien',])
plt.grid(alpha=0.5, axis='y')
plt.show()
```

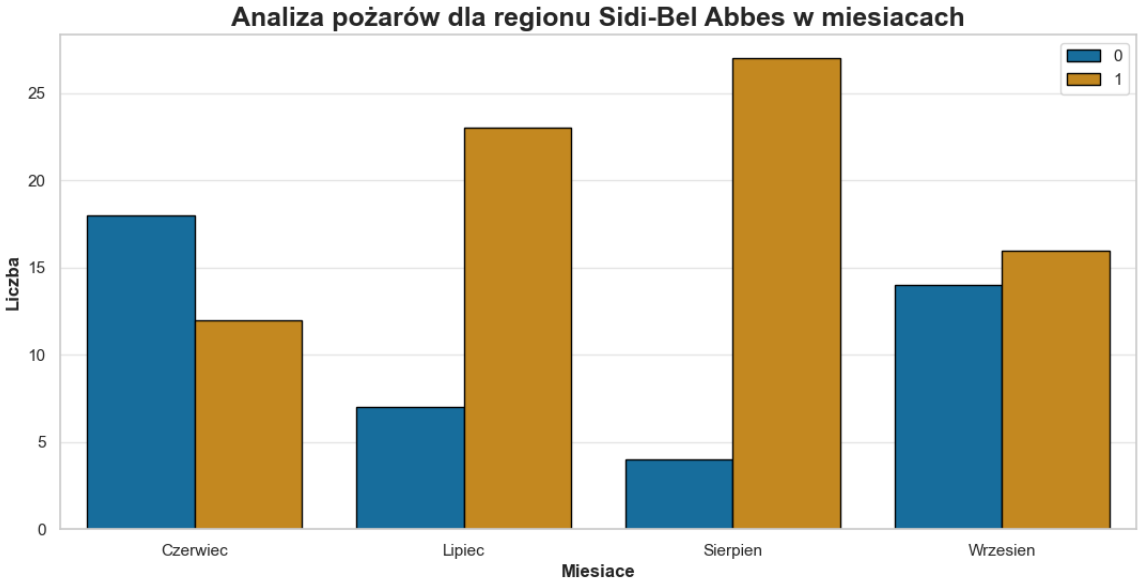

Analiza regresji

Usunięcie dnia meisiaca i roku na prztrzeby regresji analizy

In [ ]:
```
dane = dane.drop(['day', 'month', 'year'], axis=1)
dane.head(10)
```

Out[ ]:

	Temperature	RH	Ws	Rain	FFMC	DMC	DC	ISI	BUI	FWI	Classes	Region
0	29	57	18	0.0	65.7	3.4	7.6	1.3	3.4	0.5	0	1
1	29	61	13	1.3	64.4	4.1	7.6	1.0	3.9	0.4	0	1
2	26	82	22	13.1	47.1	2.5	7.1	0.3	2.7	0.1	0	1
3	25	89	13	2.5	28.6	1.3	6.9	0.0	1.7	0.0	0	1
4	27	77	16	0.0	64.8	3.0	14.2	1.2	3.9	0.5	0	1
5	31	67	14	0.0	82.6	5.8	22.2	3.1	7.0	2.5	1	1
6	33	54	13	0.0	88.2	9.9	30.5	6.4	10.9	7.2	1	1
7	30	73	15	0.0	86.6	12.1	38.3	5.6	13.5	7.1	1	1
8	25	88	13	0.2	52.9	7.9	38.8	0.4	10.5	0.3	0	1
9	28	79	12	0.0	73.2	9.5	46.3	1.3	12.6	0.9	0	1

Podział zbioru danych na funkcję wejściową i wyjściową do analizy regresji

In [ ]:
```
x = dane.iloc[:,0:10]
y= dane['FWI']
```

In [ ]:
```
x.head()
```

Out[ ]:

	Temperature	RH	Ws	Rain	FFMC	DMC	DC	ISI	BUI	FWI
0	29	57	18	0.0	65.7	3.4	7.6	1.3	3.4	0.5
1	29	61	13	1.3	64.4	4.1	7.6	1.0	3.9	0.4
2	26	82	22	13.1	47.1	2.5	7.1	0.3	2.7	0.1
3	25	89	13	2.5	28.6	1.3	6.9	0.0	1.7	0.0
4	27	77	16	0.0	64.8	3.0	14.2	1.2	3.9	0.5

In [ ]:
```
y.head()
```

Out[ ]:
```
0    0.5
1    0.4
2    0.1
3    0.0
4    0.5
Name: FWI, dtype: float64
```

Podział zestawu danych na zbiór uczący i zbiór testowy

In [ ]:
```
x_uczacy, x_testujacy, y_uczacy , y_testujacy = train_test_split(x, y, test_size
                                                    random_state=0)
x_uczacy.shape, x_testujacy.shape
```

Out[ ]:
```
((182, 10), (61, 10))
```

In [ ]:
```
x_testujacy.columns
```

Out[ ]:
```
Index(['Temperature', 'RH', 'Ws', 'Rain', 'FFMC', 'DMC', 'DC', 'ISI', 'BUI',
       'FWI'],
      dtype='object')
```

Korelacja uczących danych

In [ ]:
```
x_uczacy.corr()
```

Out[ ]:

	Temperature	RH	Ws	Rain	FFMC	DMC	DC	
Temperature	1.000000	-0.657325	-0.357016	-0.365941	0.684556	0.482965	0.349021	0.
RH	-0.657325	1.000000	0.262581	0.275592	-0.653649	-0.393893	-0.203883	-0.
Ws	-0.357016	0.262581	1.000000	0.204035	-0.226129	-0.010158	0.079699	-0.
Rain	-0.365941	0.275592	0.204035	1.000000	-0.589465	-0.300364	-0.302591	-0.
FFMC	0.684556	-0.653649	-0.226129	-0.589465	1.000000	0.621958	0.528275	0.
DMC	0.482965	-0.393893	-0.010158	-0.300364	0.621958	1.000000	0.884417	0.
DC	0.349021	-0.203883	0.079699	-0.302591	0.528275	0.884417	1.000000	0.
ISI	0.618172	-0.712353	-0.018845	-0.347660	0.742079	0.680918	0.501412	1.
BUI	0.447959	-0.333027	0.023680	-0.308258	0.606527	0.984222	0.951157	0.
FWI	0.575406	-0.594299	0.013239	-0.326426	0.704563	0.882314	0.746551	0.

In [ ]:
```
plt.figure(figsize=(12, 10))
korelacja = x_uczacy.corr()
sns.heatmap(korelacja, annot=True, cmap=plt.cm.CMRmap_r)
plt.show()
```

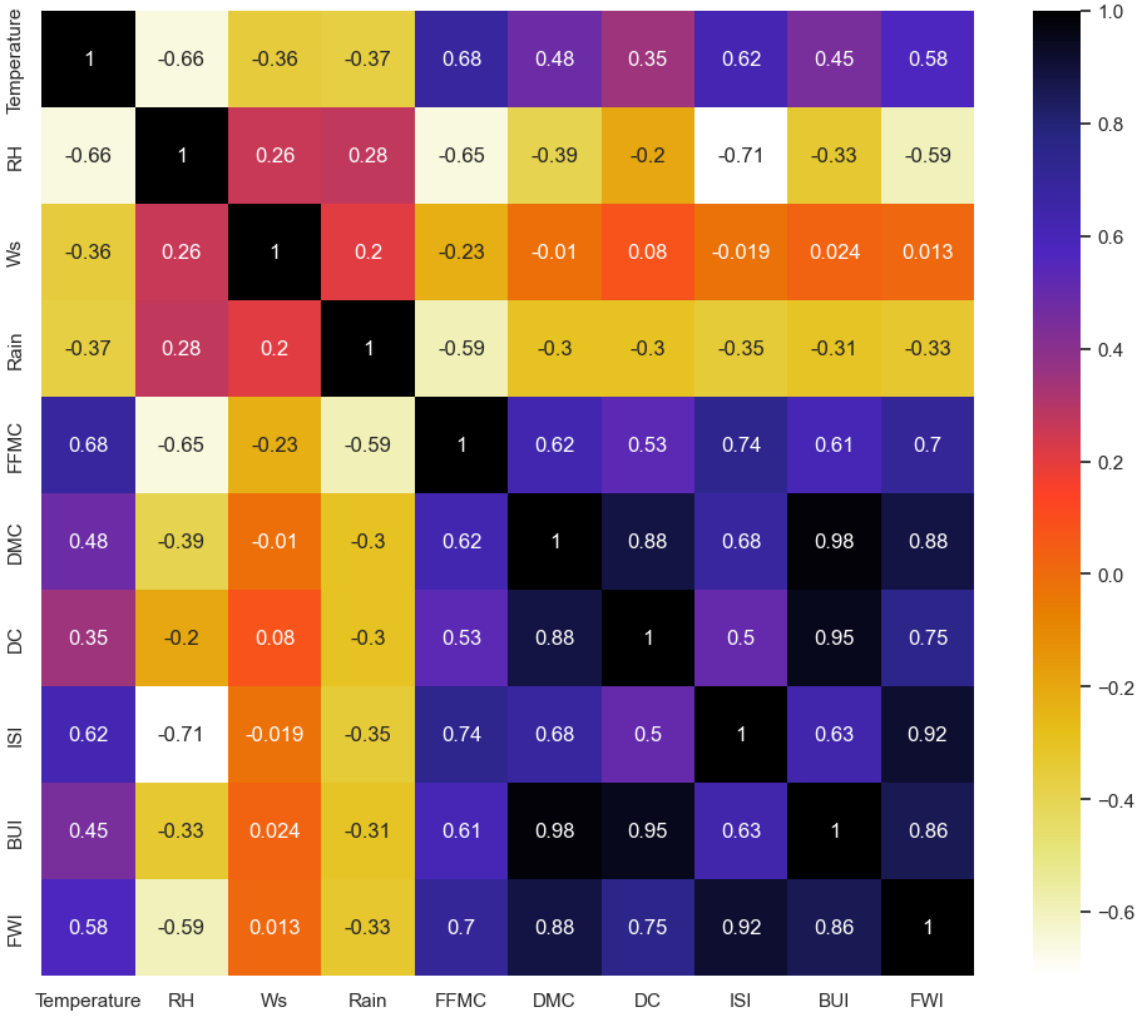

Analizując wyniki korelacji, można zauważyć, że:

- Temperatura ma silną dodatnią korelację z FFMC, a także pozytywną korelację z FWI, BUI i ISI. Oznacza to, że wyższa temperatura zwiększa poziom wysuszonych paliw, co z kolei prowadzi do wzrostu zagrożenia pożarowego.
- Wilgotność względna (RH) ma silną negatywną korelację z FFMC oraz negatywną korelację z FWI, BUI i ISI. Oznacza to, że wyższa wilgotność powietrza zmniejsza poziom wysuszonych paliw i obniża zagrożenie pożarowe.
- Prędkość wiatru (Ws) ma słabą dodatnią korelację z FFMC, a także słabą dodatnią korelację z FWI, BUI i ISI. Oznacza to, że wyższa prędkość wiatru może zwiększyć rozprzestrzenianie się pożaru.
- Opady deszczu mają negatywną korelację z FFMC, FWI, BUI i ISI. Oznacza to, że opady deszczu mogą zmniejszyć poziom wysuszonych paliw i obniżyć zagrożenie pożarowe.
- Składowe FWI (BUI, ISI, FFMC, DMC i DC) są ze sobą silnie skorelowane, co jest zrozumiałe, biorąc pod uwagę, że FWI jest złożonym wskaźnikiem, który uwzględnia wpływ wszystkich tych składowych na zagrożenie pożarowe. Warto zauważyć, że DMC i DC mają silną pozytywną korelację między sobą, co wskazuje na to, że wyższy poziom wilgoci w glebie wpływa na zwiększenie poziomu wilgoci w glebie organicznej, co z kolei zmniejsza zagrożenie pożarowe.

Sprawdzanie korelacji dla niezależnych cech, a cechy o korelacji większej niż 0,7 gdzie reszta zostanie usunieta z analizy

In [ ]:
```
def korelacjafunkcja(dane, prog):
    kolumna_korelacji = set()
    kolumna_macierzy = dane.corr()
    for i in range(len(kolumna_macierzy.columns)):
        for j in range(i):
            if abs(kolumna_macierzy.iloc[i, j]) > prog:
                colname = kolumna_macierzy.columns[i]
                kolumna_korelacji.add(colname)
    return kolumna_korelacji
```

In [ ]:
```
nowakorelacja = korelacjafunkcja(x_uczacy, 0.7)
nowakorelacja
```

Out[ ]:
```
{'BUI', 'DC', 'FWI', 'ISI'}
```

Usówanie 4 atrybutów ze wzgledu na korleacje wyzsza niz 0,7

In [ ]:
```
x_uczacy.drop(nowakorelacja, axis=1, inplace=True)
x_testujacy.drop(nowakorelacja, axis=1, inplace=True)
x_uczacy.shape
x_testujacy.shape
```

Out[ ]:
```
(61, 6)
```

Skalowanie

In [ ]:
```
def skalowaniefunkcja(x_uczacy, x_testujacy):
    skalowanie = StandardScaler()
    x_uczacy_skalowane = skalowanie.fit_transform(x_uczacy)
    x_testujacy_skalowane = skalowanie.transform(x_testujacy)

    return x_uczacy_skalowane, x_testujacy_skalowane
```

In [ ]:
```
x_uczacy_skalowane, x_testujacy_skalowane = skalowaniefunkcja(x_uczacy, x_testuj
```

In [ ]:
```
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(15, 5))
sns.boxplot(data=x_uczacy, ax=ax1)
ax1.set_title('Dane uczace przed skalowaniem')
sns.boxplot(data=x_uczacy_skalowane, ax=ax2)
ax2.set_title('Dane uczace po skalowaniu')
```

Out[ ]:
```
Text(0.5, 1.0, 'Dane uczace po skalowaniu')
```

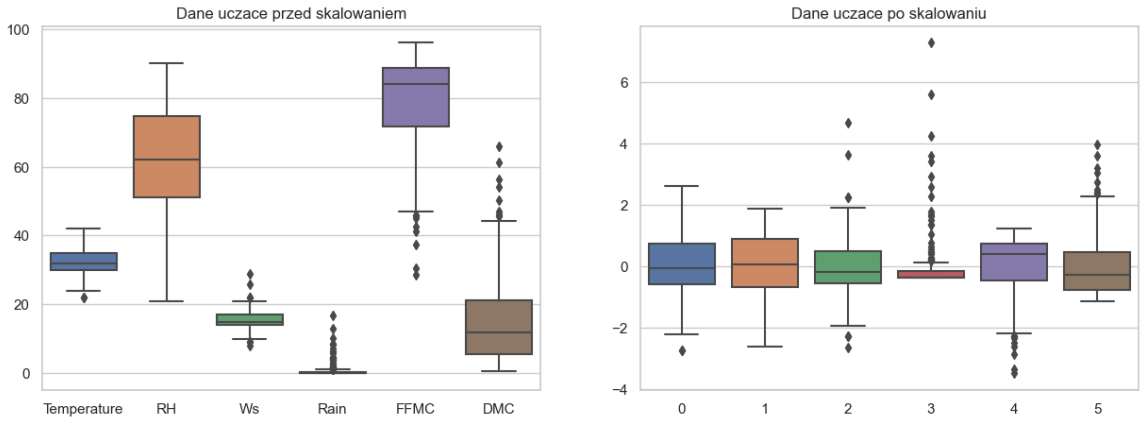

Regresja liniowa

In [ ]:
```
Regresjaliniowa = LinearRegression()
Regresjaliniowa.fit(x_uczacy_skalowane, y_uczacy)
```

Out[ ]:
```
▾ LinearRegression

LinearRegression()
```

In [ ]:
```
print('Przechwycenie wynosi :',Regresjaliniowa.intercept_)
print('Współczynnik wynosi :',Regresjaliniowa.coef_)
```

```
Przechwycenie wynosi : 7.558791208791209
Współczynnik wynosi : [ 0.36394299 -1.99797066  0.98619421  0.04636838  0.80703
533  5.44395047]
```

In [ ]:
```
print("Uczace dane wynik:",Regresjaliniowa.score(x_uczacy_skalowane, y_uczacy))
print("Testowe dane wynik:",Regresjaliniowa.score(x_testujacy_skalowane,y_testuj
```

```
Uczace dane wynik: 0.8671797758215145
Testowe dane wynik: 0.7064857305909149
```

In [ ]:
```
Regresjaliniowa_predykcja = Regresjaliniowa.predict(x_testujacy_skalowane)
Regresjaliniowa_predykcja
```

Out[ ]:
```
array([ 6.71133901, 12.02490235,  7.17708272,  8.24813881,  5.87107049,
       10.06783722, -1.57757075,  9.49762004,  6.91005123, 11.61699016,
        1.59431776, 13.00464249, 10.62115882, 12.84924636,  2.76686137,
       -0.28105695,  5.56265496,  5.29475405,  2.8722131 , -2.08125537,
       14.70243078,  5.2585157 , 11.12180353, -1.61398266,  2.36852748,
        5.45039685, 10.68723643, -0.14835576,  0.73216072,  2.91307288,
       11.58970348,  0.80835466, -1.68692435, 19.3097082 ,  2.70799081,
        2.90471917,  4.61345951, 20.52842245, 26.80883138,  6.4163819 ,
        6.1327361 ,  3.2544518 , -4.1397093 ,  3.91659235,  1.16929796,
       -5.4031485 ,  7.39875906,  4.74298501, -4.2341344 , 17.30309118,
        3.21502256,  8.83942816, -2.46778223,  0.69332504,  4.5829139 ,
        1.50799021, 10.54082105,  7.88725824,  8.47179454, 17.63579458,
        1.8425123 ])
```

In [ ]:
```
Aktualna_predykcja = pd.DataFrame(
    {'Aktualny przychod': y_testujacy, 'Predykcja przychodu': Regresjaliniowa_pr
Aktualna_predykcja
```

Out[ ]:

	Aktualny przychod	Predykcja przychodu
110	9.7	6.711339
150	7.2	12.024902
37	8.0	7.177083
75	6.3	8.248139
109	7.7	5.871070
...	...	...
179	10.9	10.540821
160	3.1	7.887258
159	3.0	8.471795
170	17.3	17.635795
221	3.7	1.842512

61 rows × 2 columns

In [ ]:
```
absolutnyblad = metrics.mean_absolute_error(y_testujacy,Regresjaliniowa_predykcj
sredniblad = metrics.mean_squared_error(y_testujacy, Regresjaliniowa_predykcja)
glownyblad = np.sqrt(metrics.mean_squared_error(
    y_testujacy, Regresjaliniowa_predykcja))

print('Aboslutny bład:', absolutnyblad)
print('Sredni bład:', sredniblad)
print('Główny bład:', glownyblad)
```

```
Aboslutny bład: 2.420707955240326
Sredni bład: 10.189169987051969
Główny bład: 3.192047929942777
```

In [ ]:
```
wynik =  r2_score(y_testujacy, Regresjaliniowa_predykcja)
print("Współczynnik determinacji:",wynik)
```

```
Współczynnik determinacji: 0.7064857305909149
```

Regresja w formie modelu OLS

In [ ]:
```
x = sm.add_constant(x)
model = sm.OLS(y, x)
results = model.fit()
print(results.summary())
```

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                    FWI   R-squared:                       1.000
Model:                            OLS   Adj. R-squared:                  1.000
Method:                 Least Squares   F-statistic:                 2.200e+30
Date:                Mon, 05 Jun 2023   Prob (F-statistic):               0.00
Time:                        11:33:52   Log-Likelihood:                 7274.7
No. Observations:                 243   AIC:                        -1.453e+04
Df Residuals:                     232   BIC:                        -1.449e+04
Df Model:                          10
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const        2.914e-15   3.16e-14      0.092      0.927   -5.93e-14    6.52e-14
Temperature -7.199e-16   6.65e-16     -1.083      0.280   -2.03e-15     5.9e-16
RH           9.008e-16   1.77e-16      5.081      0.000    5.51e-16    1.25e-15
Ws          -2.602e-16   6.42e-16     -0.406      0.685   -1.52e-15       1e-15
Rain         2.281e-16   9.83e-16      0.232      0.817   -1.71e-15    2.16e-15
FFMC        -2.299e-16   2.24e-16     -1.027      0.306   -6.71e-16    2.11e-16
DMC          4.009e-16   1.12e-15      0.358      0.720    -1.8e-15     2.6e-15
DC           2.047e-16   1.65e-16      1.240      0.216   -1.21e-16     5.3e-16
ISI         -9.168e-16   1.82e-15     -0.502      0.616   -4.51e-15    2.68e-15
BUI         -7.277e-16   1.46e-15     -0.499      0.618    -3.6e-15    2.14e-15
FWI             1.0000   1.36e-15   7.38e+14      0.000       1.000       1.000
==============================================================================
Omnibus:                        3.589   Durbin-Watson:                   0.399
Prob(Omnibus):                  0.166   Jarque-Bera (JB):                3.653
Skew:                           0.291   Prob(JB):                        0.161
Kurtosis:                       2.848   Cond. No.                     2.45e+03
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctl
y specified.
[2] The condition number is large, 2.45e+03. This might indicate that there are
strong multicollinearity or other numerical problems.
```

Przy regresji OLS znajduje sie 10 zmiennych

R-kwadrat wynosi 0,86, co oznacza, że 86% zmienności zmiennej zależnej Classes może być wyjaśnione przez zmienne niezależne w tym modelu. Współczynnik R-kwadrat skorygowany wynosi 0,854, co oznacza, że model jest dobrze dopasowany do danych.

Każda z zmiennych niezależnych ma swój współczynnik. Współczynnik jest estymowanym przeciętnym wpływem danej zmiennej niezależnej na zmienną zależną przy założeniu, że wszystkie inne zmienne niezależne są stałe. Współczynniki dla zmiennych Temperature, RH, Ws, FFMC, DMC i ISI są istotne statystycznie, ponieważ mają wartości p mniejsze niż 0,05. Oznacza to, że zmienne te mają istotny wpływ na zmienną zależną Classes.

Zmienne Rain, DC, BUI i FWI nie są istotne statystycznie, ponieważ mają wartości p większe niż 0,05. Oznacza to, że zmienne te nie mają istotnego wpływu na zmienną zależną Classes w tym modelu.

Najbardziej znaczące atrybuty

In [ ]:
```
znaczaceatrybuty = Regresjaliniowa.coef_
znaczaceatrybutytabela = pd.DataFrame({
    'Atrybuty': x_uczacy.columns,
    'Znaczenie': znaczaceatrybuty
}).sort_values('Znaczenie', ascending=False)
znaczaceatrybutytabela
```

Out[ ]:

	Atrybuty	Znaczenie
5	DMC	5.443950
2	Ws	0.986194
4	FFMC	0.807035
0	Temperature	0.363943
3	Rain	0.046368
1	RH	-1.997971

In [ ]:
```
plt.figure(figsize=(12,6))
sns.set_style('ticks')
ax = sns.barplot(data=znaczaceatrybutytabela,
                 x='Znaczenie', y='Atrybuty', ec='black')
ax.set_title('6 znaczących atrybutów', weight='bold',fontsize = 15)
ax.set_xlabel('Procent znaczenia %',weight='bold')
ax.set_ylabel('Features',weight='bold')
```

Out[ ]:
```
Text(0, 0.5, 'Features')
```

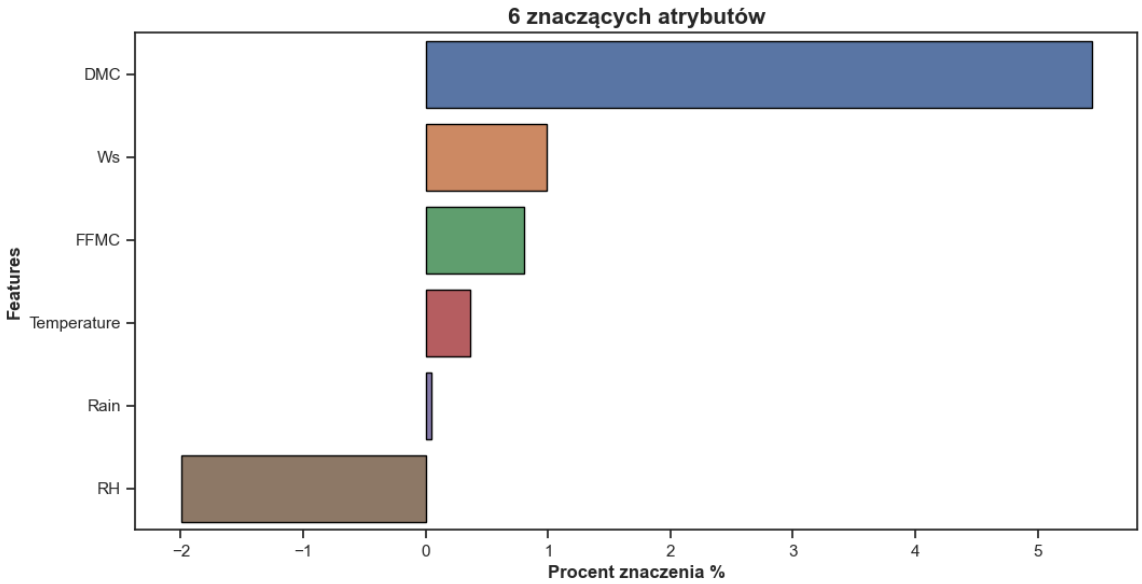

- (DMC) Indeks Kodu wilgotności Duffa - Wynosi ponad 5%
- (Ws) Prędkość wiatru Wynosi troche ponad 1%
- (FFMC) Indeks Dokładnego kodu wilgotności paliwa - prawie 1 %

- (Temperatue) Temperatura w południe maksymalna wynosi prawie 0.4 %
- (Rain) Całkowity dzień opadów wynosi troche niz 0 %
- (RH) Wilgotność względna wynosi prawie -2%

Klasyfikacja

In [ ]:
```
dane.head()
```

Out[ ]:

	Temperature	RH	Ws	Rain	FFMC	DMC	DC	ISI	BUI	FWI	Classes	Region
0	29	57	18	0.0	65.7	3.4	7.6	1.3	3.4	0.5	0	1
1	29	61	13	1.3	64.4	4.1	7.6	1.0	3.9	0.4	0	1
2	26	82	22	13.1	47.1	2.5	7.1	0.3	2.7	0.1	0	1
3	25	89	13	2.5	28.6	1.3	6.9	0.0	1.7	0.0	0	1
4	27	77	16	0.0	64.8	3.0	14.2	1.2	3.9	0.5	0	1

In [ ]:
```
x = dane.iloc[:, 0:10]
y = dane['Classes']
```

In [ ]:
```
x.head(10)
```

Out[ ]:

	Temperature	RH	Ws	Rain	FFMC	DMC	DC	ISI	BUI	FWI
0	29	57	18	0.0	65.7	3.4	7.6	1.3	3.4	0.5
1	29	61	13	1.3	64.4	4.1	7.6	1.0	3.9	0.4
2	26	82	22	13.1	47.1	2.5	7.1	0.3	2.7	0.1
3	25	89	13	2.5	28.6	1.3	6.9	0.0	1.7	0.0
4	27	77	16	0.0	64.8	3.0	14.2	1.2	3.9	0.5
5	31	67	14	0.0	82.6	5.8	22.2	3.1	7.0	2.5
6	33	54	13	0.0	88.2	9.9	30.5	6.4	10.9	7.2
7	30	73	15	0.0	86.6	12.1	38.3	5.6	13.5	7.1
8	25	88	13	0.2	52.9	7.9	38.8	0.4	10.5	0.3
9	28	79	12	0.0	73.2	9.5	46.3	1.3	12.6	0.9

In [ ]:
```
y.head(10)
```

Out[ ]:
```
0    0
1    0
2    0
3    0
4    0
5    1
6    1
7    1
8    0
9    0
Name: Classes, dtype: int32
```

In [ ]:
```
x_uczacy, x_testujacy, y_uczacy, y_testujacy = train_test_split(
    x, y, test_size=0.3, random_state=0)
x_uczacy.shape, x_testujacy.shape
```

Out[ ]:
```
((170, 10), (73, 10))
```

In [ ]:
```
x_uczacy.columns
```

Out[ ]:
```
Index(['Temperature', 'RH', 'Ws', 'Rain', 'FFMC', 'DMC', 'DC', 'ISI', 'BUI',
       'FWI'],
      dtype='object')
```

In [ ]:
```
x_testujacy.columns
```

Out[ ]:
```
Index(['Temperature', 'RH', 'Ws', 'Rain', 'FFMC', 'DMC', 'DC', 'ISI', 'BUI',
       'FWI'],
      dtype='object')
```

In [ ]:
```
korelacjanowadrzewo = korelacjafunkcja(x_uczacy, 0.7)
korelacjanowadrzewo
```

Out[ ]:
```
{'BUI', 'DC', 'FWI', 'ISI'}
```

In [ ]:
```
x_uczacy.drop(korelacjanowadrzewo, axis=1, inplace=True)
x_testujacy.drop(korelacjanowadrzewo, axis=1, inplace=True)
x_uczacy.shape, x_testujacy.shape
```

Out[ ]:
```
((170, 6), (73, 6))
```

In [ ]:
```
x_uczacy_skalowane, x_testujacy_skalowane = skalowaniefunkcja(x_uczacy, x_testuj
```

Drzewo dezycyjne

In [ ]:
```
Drzewodezycyjne = DecisionTreeClassifier()
Drzewodezycyjne.fit(x_uczacy_skalowane,y_uczacy)
```

Out[ ]:
```
▾ DecisionTreeClassifier

DecisionTreeClassifier()
```

In [ ]:
```
Drzewodezycyjne_predykcja = Drzewodezycyjne.predict(x_testujacy_skalowane)
Drzewodezycyjne_predykcja
```

Out[ ]:
```
array([1, 1, 1, 1, 1, 1, 0, 1, 1, 1, 0, 1, 1, 1, 0, 0, 0, 0, 1, 0, 1, 1,
       0, 0, 1, 0, 1, 0, 0, 0, 1, 0, 0, 1, 1, 0, 0, 1, 1, 0, 1, 0, 0, 0,
       0, 0, 1, 1, 0, 0, 1, 1, 0, 1, 1, 0, 1, 1, 1, 1, 1, 1, 0, 1, 1, 1,
       0, 0, 1, 1, 1, 0, 1])
```

In [ ]:
```
Aktualna_predykcja = pd.DataFrame(
    {'Aktualny przychod ': y_testujacy, 'Predykcjonowany przychod': Drzewodezycy
Aktualna_predykcja
```

Out[ ]:

	Aktualny przychod	Predykcjonowany przychod
110	1	1
150	1	1
37	1	1
75	1	1
109	1	1
...	...	...
89	1	1
212	1	1
74	1	1
4	0	0
108	1	1

73 rows × 2 columns

In [ ]:
```
Wynik = accuracy_score(y_testujacy, Drzewodezycyjne_predykcja)
Raport_klasyfikacyjny = classification_report(
    y_testujacy, Drzewodezycyjne_predykcja)

print("Decision Tree")
print("Accuracy Score value: {:.4f}".format(Wynik))
print(Raport_klasyfikacyjny)
```

```
Decision Tree
Accuracy Score value: 0.9863
              precision    recall  f1-score   support

           0       0.97      1.00      0.98        30
           1       1.00      0.98      0.99        43

    accuracy                           0.99        73
   macro avg       0.98      0.99      0.99        73
weighted avg       0.99      0.99      0.99        73
```

In [ ]:
```
Drzewo_macierz = ConfusionMatrixDisplay.from_estimator(
    Drzewodezycyjne, x_testujacy_skalowane, y_testujacy)
Drzewo_macierz
```

Out[ ]:
```
<sklearn.metrics._plot.confusion_matrix.ConfusionMatrixDisplay at 0x1e96e9ede90
>
```

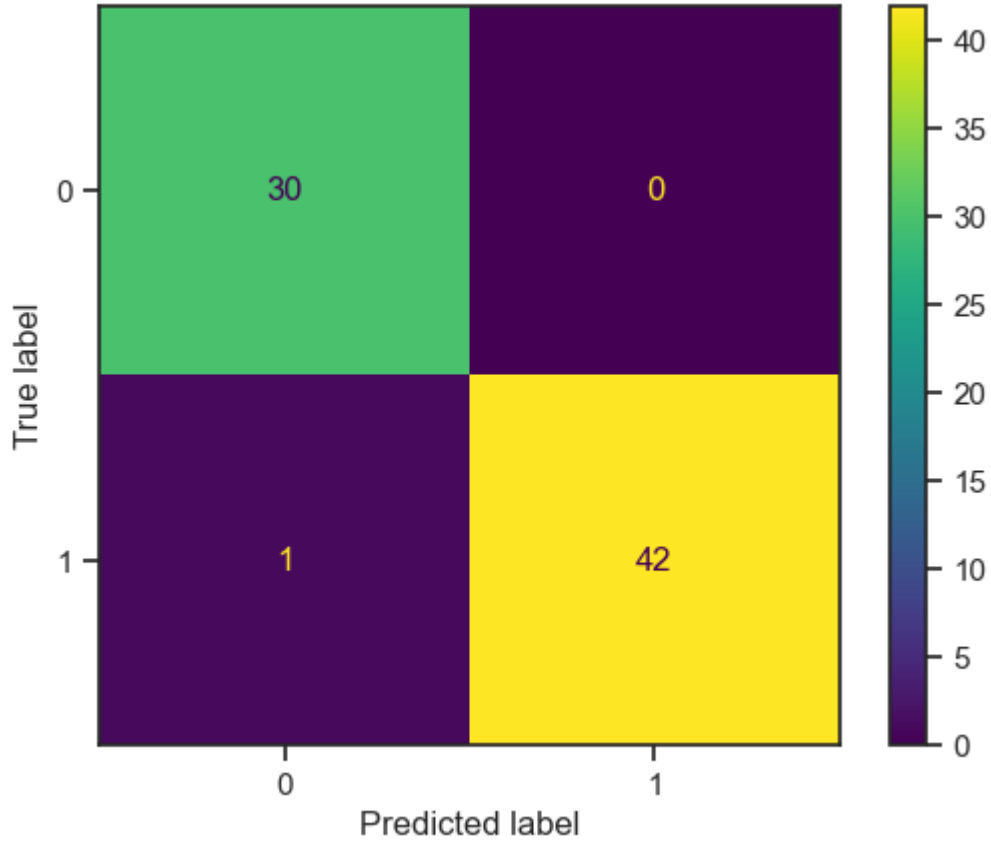

In [ ]:
```
Drzewodezycyjnestring = tree.export_text(
    Drzewodezycyjne, feature_names=x_uczacy.columns.tolist())
print(Drzewodezycyjnestring)
```

```
|--- FFMC <= 0.28
|   |--- FFMC <= 0.14
|   |   |--- class: 0
|   |--- FFMC >  0.14
|   |   |--- FFMC <= 0.20
|   |   |   |--- class: 1
|   |   |--- FFMC >  0.20
|   |   |   |--- DMC <= -0.31
|   |   |   |   |--- class: 0
|   |   |   |--- DMC >  -0.31
|   |   |   |   |--- Temperature <= 0.49
|   |   |   |   |   |--- class: 1
|   |   |   |   |--- Temperature >  0.49
|   |   |   |   |   |--- class: 0
|--- FFMC >  0.28
|   |--- class: 1
```

In [ ]:
```
plt.figure(figsize=(15, 5))
tree.plot_tree(Drzewodezycyjne, feature_names=x_uczacy.columns, filled=True)
plt.show()
```

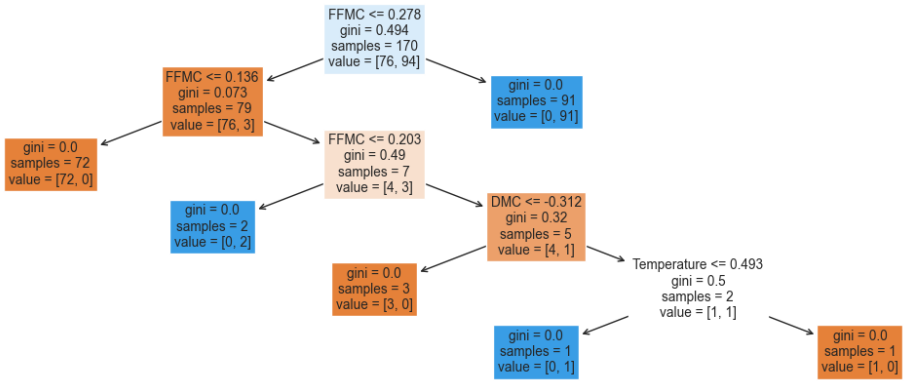

Jeśli FFMC jest mniejsze lub równe 0,28, drzewo rozgałęzia się ponownie na atrybucie FFMC. Jeśli FFMC jest mniejsze lub równe 0,14, klasa wynosi 0. Jeśli FFMC jest większe niż 0,14, ale mniejsze lub równe 0,20, klasa wynosi 1. Jeśli FFMC jest większe niż 0,20, drzewo rozgałęzia się na atrybucie DMC. Jeśli DMC jest mniejsze lub równe -0,31, klasa wynosi 0. Jeśli DMC jest większe niż -0,31, drzewo rozgałęzia się na atrybucie Temperatura. Jeśli Temperatura jest mniejsza lub równa 0,49, klasa wynosi 1. Jeśli Temperatura jest większa niż 0,49, klasa wynosi 0. Jeśli FFMC jest większe niż 0.28, klasa wynosi 1.